

Sistema Híbrido Bioinspirado con Aprendizaje por Refuerzo

Buffer de Replay CLONALG acoplado a DQN

Aprendizaje Automático Bioinspirado (APBIO)

Universidad de Vigo — Curso 2025–2026

Tu Nombre Aquí

9 de mayo de 2026

Resumen

Este trabajo presenta un sistema híbrido que acopla el algoritmo de selección clonal CLONALG con un agente de aprendizaje por refuerzo profundo DQN para resolver el entorno **LunarLander-v3** de Gymnasium. CLONALG reemplaza el buffer de replay aleatorio estándar: las transiciones se almacenan como anticuerpos con afinidad proporcional al error temporal (TD-error), y el muestreo del mini-batch se guía por selección clonal con supresión clonal para garantizar diversidad. Los experimentos sobre 5 semillas independientes y 300 episodios revelan que el sistema CLONALG+DQN no supera al baseline DQN (retorno medio $-245,4 \pm 130,2$ frente a $208,7 \pm 22,1$), siendo la diferencia estadísticamente significativa ($t = 7,76$, $p = 0,001$). El análisis identifica como causa principal la ausencia de *importance sampling weights* para corregir el sesgo introducido por el muestreo no uniforme. El proceso de desarrollo fue iterativo e implicó cuatro rediseños del buffer para resolver inestabilidad numérica, documentados en detalle en este informe como parte del proceso científico.

0 Índice

1. Introducción	2
2. Antecedentes y Estado del Arte	3
2.1. Deep Q-Network (DQN)	3
2.2. CLONALG	3
2.3. Prioritized Experience Replay (PER)	4
3. Metodología	4
3.1. Entorno experimental	4
3.2. Arquitectura del sistema híbrido	5
3.3. Componente bioinspirado: CLONALG como buffer	6
3.4. Prueba de validez del acoplamiento	6
3.5. Proceso de desarrollo: dificultades e iteraciones	7
3.5.1. Iteración 1: listas Python y afinidades sin normalizar	7
3.5.2. Iteración 2: arrays numpy y supresión vectorizada	7
3.5.3. Iteración 3: clip de afinidades y normalización	8
3.5.4. Iteración 4: mezcla uniforme y clip agresivo (diseño final)	8
3.5.5. Causa raíz identificada: ausencia de importance sampling weights	8
3.6. Configuración experimental	8
4. Resultados	9
4.1. Curvas de aprendizaje	9
4.2. Estudio de ablación	10
4.3. Diagnósticos del módulo bioinspirado	11
4.4. Barrido de hiperparámetros	11
5. Discusión	12
6. Conclusiones	13

1 Introducción

El aprendizaje por refuerzo profundo (DRL) ha experimentado avances extraordinarios en la última década, demostrando capacidad para resolver tareas de control complejas que antes se consideraban inabordables para máquinas [4]. Entre los algoritmos más influyentes destaca DQN (*Deep Q-Network*), que fue el primer método en combinar redes neuronales profundas con aprendizaje por refuerzo a escala, logrando un rendimiento sobrehumano en videojuegos Atari.

Sin embargo, DQN es sensible a la correlación entre muestras consecutivas, ya que las transiciones generadas por la interacción del agente con el entorno están temporalmente correladas. Este problema motivó la introducción del buffer de replay [3]: una memoria que almacena transiciones pasadas y permite extraer mini-batches de forma aleatoria, rompiendo la correlación temporal y estabilizando el entrenamiento.

El muestreo aleatorio uniforme del buffer, aunque efectivo, tiene una limitación importante: ignora la relevancia relativa de las experiencias almacenadas. Una transición con alta señal de aprendizaje (por ejemplo, un aterrizaje exitoso en las primeras etapas del entrenamiento) recibe el mismo peso que una transición trivial. Esta ineficiencia motivó el desarrollo del Prioritized Experience Replay [5], que prioriza transiciones según su TD-error.

Los algoritmos inmunológicos artificiales, inspirados en la respuesta inmune adaptativa biológica, ofrecen mecanismos de selección y diversidad bien fundamentados matemáticamente [1]. En particular, CLONALG [2] implementa selección clonal proporcional a la afinidad y supresión clonal para mantener diversidad en el repertorio. Estas propiedades son naturalmente compatibles con el problema de gestión del buffer de replay: la afinidad puede codificar la relevancia de una transición, y la supresión clonal puede garantizar diversidad en el mini-batch seleccionado.

Este trabajo propone acoplar CLONALG como gestor activo del buffer de replay de DQN. Cada transición se almacena como un anticuerpo cuya afinidad refleja su relevancia para el aprendizaje (medida mediante el TD-error). El sistema crea un flujo bidireccional genuino: CLONALG selecciona qué transiciones usa DQN para aprender, y DQN informa a CLONALG de qué transiciones resultaron más relevantes mediante los TD-errors reales.

El artículo está organizado como sigue: la Sección 2 revisa los antecedentes necesarios, la Sección 3 describe la metodología y el proceso de desarrollo completo incluyendo las dificultades encontradas, la Sección 4 presenta los resultados experimentales, la Sección 5 discute los hallazgos respondiendo las diez preguntas de evaluación del enunciado, y la Sección 6 concluye el trabajo.

2 Antecedentes y Estado del Arte

2.1 Deep Q-Network (DQN)

El algoritmo DQN [4] aproxima la función de valor-acción $Q(s, a)$ mediante una red neuronal con parámetros θ , optimizando la pérdida de Bellman:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (1)$$

donde θ^- son los pesos de la red objetivo (*target network*), actualizada periódicamente mediante copia completa de θ , y $\mathcal{D}$ es el buffer de replay del que se extraen las muestras.

El algoritmo usa una política ε -greedy para balancear exploración y explotación: con probabilidad ε selecciona una acción aleatoria, y con probabilidad $1 - \varepsilon$ selecciona la acción de mayor valor Q . El parámetro ε decae exponencialmente durante el entrenamiento desde 1.0 hasta un valor mínimo, pasando de exploración pura a explotación progresiva.

En nuestra implementación, la red Q tiene dos capas ocultas de 128 neuronas con activaciones ReLU. El optimizador es Adam con gradient clipping (`max_norm=1.0`) para estabilidad numérica.

2.2 CLONALG

CLONALG [2] es un algoritmo evolutivo basado en el principio de selección clonal del sistema inmune adaptativo. Opera sobre un repertorio $\mathcal{R}$ de anticuerpos, cada uno con una afinidad que mide su relevancia respecto al problema. El algoritmo sigue estos pasos en cada generación:

1. **Selección:** seleccionar los n anticuerpos de mayor afinidad.
2. **Clonación:** clonar cada anticuerpo proporcionalmente a su afinidad ($n_c^i \propto f_i$), creando una población de clones.
3. **Hipermutación:** mutar los clones con tasa inversamente proporcional a la afinidad (los mejores se mutan menos, conservando sus propiedades).
4. **Maduración por afinidad:** evaluar los clones mutados y seleccionar los mejores de cada familia clonal.
5. **Supresión clonal:** eliminar anticuerpos demasiado similares entre sí (similitud mayor que un umbral σ_s), manteniendo diversidad en el repertorio.

6. **Reemplazo:** sustituir los peores anticuerpos del repertorio por los mejores clones madurados.

En nuestra adaptación al contexto de buffer de replay, los anticuerpos son transiciones de experiencia (s, a, r, s') , la afinidad codifica la relevancia de cada transición para el aprendizaje actual, y la supresión clonal garantiza que el mini-batch entregado a DQN no contenga transiciones redundantes.

2.3 Prioritized Experience Replay (PER)

El trabajo más cercano al propuesto es PER [5], que asigna a cada transición una probabilidad de muestreo proporcional a su TD-error: $P(i) = p_i^\alpha / \sum_k p_k^\alpha$, con $p_i = |\delta_i| + \epsilon$. Para mantener la convergencia teórica, PER introduce *importance sampling weights*:

$$w_i = \left(\frac{1}{N \cdot P(i)} \right)^\beta \quad (2)$$

que corrigen el sesgo introducido por el muestreo no uniforme, multiplicando los gradientes por w_i antes de actualizar θ . Este mecanismo es esencial para la convergencia; como se verá en la Sección 3, su ausencia en nuestra implementación es la causa raíz de la divergencia de CLONALG+DQN.

La diferencia principal entre PER y nuestra propuesta es que CLONALG añade supresión clonal para garantizar diversidad en el mini-batch, algo que PER no tiene. Sin embargo, al carecer de importance sampling weights, CLONALG no puede garantizar la corrección del sesgo de muestreo.

3 Metodología

3.1 Entorno experimental

Se utiliza **LunarLander-v3** [6] de Gymnasium. El agente recibe un vector de observación $s \in \mathbb{R}^8$ que incluye posición (x, y) , velocidades $(\dot{x}, \dot{y})$, ángulo θ y su derivada $\dot{\theta}$, y dos indicadores binarios de contacto de las patas. El espacio de acciones es discreto con 4 opciones: no hacer nada, encender el motor izquierdo, encender el motor principal, o encender el motor derecho.

La función de recompensa recompensa el acercamiento al punto de aterrizaje, penaliza el crash (-100), y añade pequeñas recompensas o penalizaciones por cada step según la posición y velocidad. Una puntuación superior a $+200$ puntos acumulados en un episodio se considera éxito.

Este entorno fue seleccionado por tres razones. Primero, presenta recompensas dispersas al inicio del entrenamiento, haciendo que un buffer inteligente que priorice transiciones informativas sea especialmente relevante. Segundo, el espacio de estados continuo de dimensión 8 permite usar la similitud coseno para la supresión clonal de forma significativa. Tercero, es computacionalmente manejable, cumpliendo el requisito de reproducibilidad en menos de dos horas.

3.2 Arquitectura del sistema híbrido

La Figura 1 muestra la arquitectura completa del sistema. El componente bioinspirado actúa en el **punto de inserción 3** (memoria de experiencia / replay) del bucle de RL, tal como se define en el enunciado del proyecto.




Figura 1: Arquitectura completa del sistema híbrido CLONALG+DQN. Las flechas continuas indican flujo de datos de entrenamiento; las flechas discontinuas indican retroalimentación de TD-errors desde DQN hacia el buffer CLONALG. El recuadro punteado delimita el componente bioinspirado.

El flujo de datos completo opera como sigue:

1. El entorno genera transiciones (s, a, r, s') que se almacenan en el repertorio CLONALG como anticuerpos con afinidad inicial neutra ($f_i = 1$).
2. Cuando el buffer supera el tamaño mínimo (`min_buffer=500`), el agente solicita un mini-batch al buffer CLONALG.
3. CLONALG selecciona candidatos con probabilidad proporcional a la afinidad (mezclada con muestreo uniforme al 50 % para estabilidad), aplica supresión

clonal para garantizar diversidad, y entrega el batch de 64 transiciones a DQN.

4. DQN realiza un paso de gradiente usando el batch y devuelve los TD-errors por muestra ($|\delta_i|$) al buffer CLONALG.
5. CLONALG actualiza las afinidades de las transiciones del batch usando una media móvil exponencial con los TD-errors recibidos, completando el ciclo bidireccional $DQN \rightarrow CLONALG$.
6. El agente selecciona una acción con política ε -greedy y la ejecuta en el entorno, generando la siguiente transición.

3.3 Componente bioinspirado: CLONALG como buffer

Cada transición (s_i, a_i, r_i, s'_i) se almacena como un anticuerpo con afinidad $f_i \in [0,01, 2]$. Cuando el repertorio alcanza su capacidad máxima N , se reemplaza el anticuerpo de menor afinidad (selección clonal inversa), manteniendo las transiciones más informativas.

Las probabilidades de muestreo mezclan sesgo por afinidad con muestreo uniforme para estabilidad numérica:

$$P(i) = \frac{1}{2} \cdot \frac{(f_i - f_{\min} + \varepsilon)^{0,3}}{\sum_j (f_j - f_{\min} + \varepsilon)^{0,3}} + \frac{1}{2N} \quad (3)$$

El exponente 0,3 suaviza el sesgo para evitar que unas pocas transiciones con afinidad muy alta dominen completamente el muestreo.

La supresión clonal usa similitud coseno normalizada al rango $[0, 1]$:

$$\text{sim}(i, j) = \frac{\mathbf{s}_i \cdot \mathbf{s}_j}{\|\mathbf{s}_i\| \|\mathbf{s}_j\| + \varepsilon} \cdot \frac{1}{2} + \frac{1}{2} \quad (4)$$

Candidatos con $\text{sim}(i, j) > \sigma_s$ son suprimidos, garantizando que el mini-batch final incluye transiciones que corresponden a estados diferentes del entorno.

La actualización de afinidades con los TD-errors reales de DQN es el mecanismo de retroalimentación que hace el acoplamiento adaptativo:

$$f_i \leftarrow 0,9 f_i + 0,1 \cdot \text{clip}(|\delta_i|, 0,01, 2,0) \quad (5)$$

3.4 Prueba de validez del acoplamiento

Aplicando las tres preguntas de validez del enunciado:

1. **¿Funciona sin el componente bioinspirado?** Sí: sustituyendo CLONALG por un buffer aleatorio uniforme se obtiene el DQN baseline estándar. La ablación es directa y limpia.
2. **¿Tiene parámetros adaptativos que cambian durante el entrenamiento?** Sí: las afinidades $\{f_i\}$ del repertorio se actualizan en cada step de entrenamiento mediante la Ecuación 5, usando los TD-errors reales computados por la red Q.
3. **¿Se puede dibujar un diagrama de flujo de datos?** Sí: la Figura 1 muestra el flujo completo. Las transiciones (s, a, r, s') fluyen de env a CLONALG; arrays numpy de shape $(64, 8)$, $(64,)$, $(64,)$, $(64, 8)$, $(64,)$ fluyen de CLONALG a DQN; un array de TD-errors de shape $(64,)$ fluye de DQN a CLONALG.

3.5 Proceso de desarrollo: dificultades e iteraciones

El desarrollo del sistema híbrido implicó cuatro versiones del buffer CLONALG, cada una resolviendo los problemas de la anterior. Documentamos este proceso porque forma parte integral del método científico y permite comprender los resultados finales.

3.5.1 Iteración 1: listas Python y afinidades sin normalizar

La primera implementación usó listas Python con operaciones $O(n)$ para inserción y eliminación, y un bucle Python anidado para la supresión clonal con coste $O(k^2)$.

Esta implementación resultó excesivamente lenta: cada run de 500 episodios tardaba más de 100 minutos en una GPU RTX 3060, mientras que el baseline completaba 500 episodios en ~ 11 minutos. Adicionalmente, las afinidades se inicializaban con el TD-error absoluto sin normalizar, produciendo valores de 10^2 – 10^3 y pérdidas de 10^{14} por distribuciones de muestreo degeneradas.

3.5.2 Iteración 2: arrays numpy y supresión vectorizada

Se sustituyeron las listas por arrays numpy pre-allocados y la supresión clonal se vectorizó mediante multiplicación matricial: $\mathbf{S} = \mathbf{V}_{\text{norm}} \mathbf{V}_{\text{norm}}^\top$. Esto redujo el tiempo de 100+ minutos a 3–8 minutos por run. Sin embargo, la pérdida seguía explotando (10^4 – 10^6) por las afinidades sin normalizar.

3.5.3 Iteración 3: clip de afinidades y normalización

Se clippearon las afinidades a $[0,01, 10,0]$ con normalización por desplazamiento mínimo. La pérdida se redujo a 10^3 – 10^4 , pero las transiciones con afinidad alta seguían dominando el muestreo, manteniendo la divergencia.

3.5.4 Iteración 4: mezcla uniforme y clip agresivo (diseño final)

Se introdujo la mezcla 50/50 con muestreo uniforme (Ecuación 3) y el clip se redujo a $[0,01, 2,0]$. La pérdida se estabilizó en el rango 30–400, siendo este el diseño final evaluado experimentalmente.

3.5.5 Causa raíz identificada: ausencia de importance sampling weights

El análisis post-hoc revela que la inestabilidad residual se debe a la ausencia de importance sampling weights. Al sesgar el muestreo hacia transiciones de alto TD-error sin corregir el gradiente, la red Q sobreajusta a los casos más difíciles antes de dominar los fáciles, creando el siguiente ciclo de retroalimentación negativa:

1. Transiciones difíciles (alto TD-error) reciben alta afinidad.
2. CLONALG las selecciona frecuentemente.
3. DQN entrena desproporcionadamente en ellas sin corrección del sesgo.
4. El gradiente sesgado deteriora la estimación Q en transiciones fáciles.
5. El TD-error de las transiciones fáciles aumenta y reciben más afinidad.
6. El repertorio converge a un conjunto de transiciones difíciles que la red Q no puede aprender bien, causando divergencia progresiva.

PER [5] resuelve exactamente este problema mediante $w_i \propto P(i)^{-\beta}$ (Ecuación 2).

3.6 Configuración experimental

La Tabla 1 resume todos los hiperparámetros del sistema. Todos los experimentos usaron 5 semillas independientes $\{0, 1, 2, 3, 4\}$ con 300 episodios cada una. El barrido de hiperparámetros usó 3 semillas con 300 episodios por configuración.

Cuadro 1: Hiperparámetros del sistema híbrido CLONALG+DQN.

Parámetro	Descripción	Valores barridos	Valor final
N	Capacidad buffer	500, 1000, 2000	2000
β_c	Tasa de clonación	0.3, 0.5, 0.7	0.5 (indiferente)
lr	Tasa aprendizaje DQN	10^{-4} , 5×10^{-4} , 10^{-3}	10^{-4}
σ_s	Umbral supresión clonal	—	0.95
γ	Factor descuento	—	0.99
$\varepsilon_{\text{mín}}$	Epsilon mínimo	—	0.05
$\varepsilon_{\text{decay}}$	Decaimiento epsilon	—	0.995
batch	Tamaño mini-batch	—	64
min_buffer	Buffer mínimo para entrenar	—	500
hidden	Neuronas por capa oculta	—	128
target_freq	Frecuencia actualización target net	—	200

Los experimentos se ejecutaron en un PC con GPU NVIDIA RTX 3060 (12 GB VRAM), 32 GB RAM y Python 3.11 con PyTorch 2.x (CUDA 12.1).

4 Resultados

4.1 Curvas de aprendizaje




Figura 2: Retorno por episodio suavizado con ventana móvil de 20 episodios. Izquierda: media $\pm$ desviación estándar entre las 5 semillas. Derecha: curvas individuales de cada semilla. Línea discontinua: umbral de éxito (+200 puntos).

La Figura 2 muestra las curvas de aprendizaje de ambos sistemas. El baseline DQN (azul) exhibe convergencia clásica: retornos negativos durante los primeros 50–100 episodios de exploración, mejora gradual, y convergencia hacia el umbral de éxito a partir del episodio ~ 200 . El retorno medio de los últimos 50 episodios es $208,7 \pm 22,1$, superando el umbral en todas las semillas.

El sistema CLONALG+DQN (naranja) muestra mejora inicial hasta ~ -100 en los episodios 50–80, seguida de degradación sostenida hasta valores de -200 a -500 . El retorno medio final es $-245,4 \pm 130,2$. La alta varianza entre semillas (desv. est. 130.2 frente a 22.1 del baseline) evidencia la inestabilidad del acoplamiento.

4.2 Estudio de ablación




Figura 3: Estudio de ablación. Izquierda: curvas de retorno medio suavizado. Derecha: distribución del retorno medio de los últimos 50 episodios por semilla (boxplot). Test t de Welch: $t = 7,76$, $p = 0,001$.

La Figura 3 aísla la contribución del módulo CLONALG. El boxplot muestra claramente que el baseline produce retornos consistentemente superiores (mediana ~ 210 , rango estrecho) frente a CLONALG+DQN (mediana ~ -240 , rango amplio). La prueba t de Welch da $t = 7,76$, $p = 0,001$, confirmando significación estadística al nivel $\alpha = 0,05$. La mejora relativa es:

$$\Delta = \frac{R_{\text{CLONALG}} - R_{\text{baseline}}}{|R_{\text{baseline}}|} = \frac{-245,4 - 208,7}{208,7} = -2,17 \quad (6)$$

El sistema híbrido rinde un 217% peor que el baseline.

4.3 Diagnósticos del módulo bioinspirado




Figura 4: Diagnósticos internos del módulo CLONALG. Izquierda: evolución de la afinidad media del repertorio (media $\pm$ desv. est. entre semillas). Derecha: pérdida de entrenamiento clippeada a 500.

La Figura 4 revela un comportamiento interno coherente del módulo CLONALG. La afinidad media del repertorio (izquierda) aumenta de ~ 0 a $\sim 1,8$ durante los primeros 40 episodios y se estabiliza con baja varianza, indicando que el módulo aprende correctamente a distinguir transiciones por relevancia. Sin embargo, esta señal interna correcta no se traduce en mejor aprendizaje de la política: la pérdida de CLONALG+DQN (derecha) asciende progresivamente hasta ~ 200 – 400 , mientras que el baseline se mantiene próxima a cero.

4.4 Barrido de hiperparámetros




Figura 5: Barrido sistemático de hiperparámetros. Retorno medio de los últimos 50 episodios (3 semillas) para cada valor de los tres hiperparámetros barridos. Barras de error: desviación estándar.

La Figura 5 presenta tres hallazgos. Primero, la capacidad N tiene impacto positivo: $N = 2000$ obtiene -163 frente a -336 de $N = 500$. Segundo, la tasa de clonación β_c no tiene efecto observable: los tres valores producen retornos idénticos, indicando que la supresión clonal domina la selección independientemente de cuántos candidatos se generen. Tercero, $\text{lr} = 10^{-4}$ es la configuración más estable.

5 Discusión

P1. No. CLONALG+DQN obtiene $-245,4 \pm 130,2$ frente a $208,7 \pm 22,1$ del baseline ($t = 7,76$, $p = 0,001$). La diferencia es estadísticamente significativa. El híbrido tampoco supera al baseline en eficiencia muestral: el baseline cruza $+200$ alrededor del episodio 200, mientras CLONALG+DQN nunca alcanza valores positivos de forma sostenida.

P2. La capacidad del buffer N tiene el mayor efecto ($\Delta = 173$ puntos entre $N = 500$ y $N = 2000$). La tasa de clonación β_c no tiene efecto observable (resultados idénticos para 0.3, 0.5 y 0.7), revelando que la supresión clonal domina la diversidad del batch independientemente de cuántos candidatos se generen. El umbral de supresión σ_s es probablemente el parámetro bioinspirado realmente determinante, aunque no fue barrido en este experimento.

P3. CLONALG+DQN no converge a una política estable. Las curvas muestran mejora inicial seguida de degradación sostenida. La pérdida de entrenamiento crece progresivamente, evidenciando divergencia de la red Q por el ciclo de retroalimentación negativa descrito en la Sección 3. El baseline sí converge a política estable a partir del episodio ~ 200 .

P4. Alta sensibilidad en CLONALG+DQN (desv. est. 130.2, rango -459 a -107) frente a baja en el baseline (22.1, rango 176 a 229). La varianza de CLONALG+DQN es intrínseca: las afinidades iniciales dependen de las primeras transiciones generadas, que varían con la semilla, amplificando o atenuando la divergencia posterior.

P5. Mejor configuración: $N = 2000$, $\text{lr} = 10^{-4}$, $\beta_c = 0,5$ (indiferente), $\sigma_s = 0,95$, $\gamma = 0,99$, $\varepsilon_{\text{mín}} = 0,05$, **batch**=64. Retorno medio: -163 ± 234 .

P6. Sí. La afinidad media evoluciona de ~ 0 a $\sim 1,8$ en los primeros 40 episodios y se estabiliza con baja varianza. El módulo aprende a asignar mayor afinidad a transiciones con TD-error alto. Esta convergencia interna es coherente con el diseño, aunque no se traduce en mejor aprendizaje de la política por la causa raíz identificada.

P7. Sí, bidireccional: CLONALG $\rightarrow$ DQN mediante el batch con diversidad garan-

tizada; DQN $\rightarrow$ CLONALG mediante TD-errors reales. Sin la retroalimentación, las afinidades quedan fijas en 1 y el sistema degenera en muestreo uniforme con supresión clonal.

P8. Baseline: 7–11 min/seed. CLONALG+DQN: 3–8 min/seed (GPU RTX 3060). CLONALG es paradójicamente más rápido porque los episodios son más cortos (el agente falla antes). La supresión vectorizada tiene coste $O(k^2)$ con $k = 192$, negligible frente al forward/backward pass de la red Q. La primera implementación con bucles Python era prohibitiva (> 100 min/seed).

P9. PER [5] replicaría la priorización por TD-error con importance sampling corrector, pero sin supresión clonal para diversidad. Lo que CLONALG añade: (a) supresión clonal basada en similitud coseno entre estados, y (b) reemplazo del anticuerpo de menor afinidad en lugar de reemplazo FIFO. La pérdida funcional respecto a PER sería la corrección del sesgo de muestreo, que resulta ser la diferencia crítica para la convergencia.

P10. En su estado actual, no. El sistema híbrido rinde significativamente peor que el baseline ($\Delta = -217\%$, $p = 0,001$). La extensión más prometedora es añadir importance sampling weights al buffer CLONALG, que debería corregir el sesgo mientras mantiene la diversidad garantizada como ventaja diferencial. En entornos con espacios de estado de alta dimensión y recompensas muy dispersas, la supresión clonal podría ser especialmente valiosa.

6 Conclusiones

Este trabajo implementa y evalúa un sistema híbrido que acopla CLONALG como buffer de replay inteligente para DQN en LunarLander-v3. El proceso de desarrollo fue iterativo: cuatro versiones del buffer fueron necesarias para resolver la inestabilidad numérica inicial (pérdidas de 10^{14}) y los tiempos de ejecución prohibitivos (> 100 min/seed) de la primera implementación. La vectorización con numpy y la mezcla 50/50 con muestreo uniforme resolvieron ambos problemas.

Los resultados experimentales son claros: el baseline DQN converge a $208,7 \pm 22,1$, mientras CLONALG+DQN se estabiliza en $-245,4 \pm 130,2$ ($t = 7,76$, $p = 0,001$). El módulo CLONALG funciona internamente de forma coherente (la afinidad converge correctamente), pero la ausencia de importance sampling weights crea un ciclo de retroalimentación negativa que diverge la red Q.

El experimento aporta tres contribuciones. Primero, implementación funcional y reproducible de CLONALG como buffer de replay con supresión clonal vectorizada.

Segundo, identificación precisa de la causa de divergencia comparando con PER: la corrección del sesgo de muestreo es el mecanismo crítico ausente. Tercero, el hallazgo de que β_c (tasa de clonación) es irrelevante cuando σ_s (umbral de supresión) domina la diversidad del batch, sugiriendo que el trabajo futuro debería centrarse en el barrido de σ_s e incorporar importance sampling weights.

6 Referencias

- [1] Dipankar Dasgupta. *Artificial immune systems and their applications*. Springer, 1999.
- [2] Leandro N. de Castro and Fernando J. Von Zuben. Learning and optimization using the clonal selection principle. volume 6, pages 239–251, 2002.
- [3] Long-Ji Lin. Self-improving reactive agents based on reinforcement learning, planning and teaching. *Machine Learning*, 8:293–321, 1992.
- [4] Volodymyr Mnih et al. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015.
- [5] Tom Schaul et al. Prioritized experience replay. *arXiv preprint arXiv:1511.05952*, 2015.
- [6] Mark Towers et al. Gymnasium: A standard api for reinforcement learning, 2023.